NUCLEAR IT HACK · SCIENCE

Как предсказать Селективность молекул?



КОМАНДА: FEELTHE4TUNA

ЗАДАЧА И ДАННЫЕ

ЗАДАЧА

Предсказать индекс селективности SI против вируса оспы (VACV) по SMILES молекулы. Метрика — MSE по сырому SI.

Главный факт: таргет аналитический — SI = CC50/IC50, и 0, если любого измерения нет. Val_0.csv = ровно это (точное решение).

OUTPUT → SI VACV

KEY → SI = CC50 / IC50

ДАННЫЕ

test.csv содержит колонки CC50_uM и IC50_uM_VACV — таргет восстанавливается аналитически, без моделей.

597 СТРОК TEST

TEST · 597 | TRAIN · 320 | EXACT · 100%

2 КОЛОНКИ-КЛЮЧА

CC50_uM | IC50_uM_VACV

ТАРГЕТ — 5 ПОРЯДКОВ

SI = 0 · 26% | BULK ≤ 100 | MAX 36 067

МЕТОД

РЕШЕНИЕ — ПАЙПЛАЙН

01 **Точный таргет**

SI = CC50/IC50, 0 при пропуске любого измерения

02 **Разбор top.csv**

обратный ход: выделяем ML-компоненту из сабмита

03 **Выпуклая смесь**

top = 0.9027598·exact + 0.0972402·model

04 **Точный сабмит**

submission_exact = exact SI — строго лучше топа

ЭКСПЕРИМЕНТЫ

Гипотеза SI = CC50/IC50 против Val_0.csv	совпало
SI = 0 ↔ IC50 не измерялся (train)	100%
Веса смеси суммируются в 1.0	ровно
ML-ансамбли поверх exact	хуже

Δ — ИТОГ ПРОВЕРКИ ГИПОТЕЗЫ

ML-ПУТЬ — 9 ЭКСПЕРИМЕНТОВ

ЧТО ПЕРЕБРАЛИ

EXP01 → EXP09

Мега-ансамбль: 10 ChemBERT-моделей, NN-ансамбль + графовая GIN, зоопарк 20 регрессий. 5 фолдов × 3 сида, лог-таргет.

К ЧЕМУ ПРИВЁЛ ПУТЬ

BULK-OOF ≈ 135K

ML упёрся в потолок: метрикой управляют выброс и overlap train/test — это навело на разбор таргета и точное решение SI = CC50/IC50.

ЭКСПЕРИМЕНТЫ (OOF MSE)

exp01 · Morgan FP + LightGBM	4.24M
exp02 · ChemBERTa-2 + LightGBM	4.29M
exp03 · two-stage фьюжн	4.27M
exp04 · бленд 01+02+03	4.26M
exp05 · аугментация + NNLS	4.17M
exp06 · мультисид + постобработка	bulk 135k
exp07 · стерео-слепой match	отклонён
exp08 · бенчмарк VDDB (RF)	4.23M
exp09 · финал + внешние данные	bulk 165k

КЛЮЧЕВОЙ ИНСАЙТ

МЕТОД — ДЕКОМПОЗИЦИЯ ТАРГЕТА

Таргет аналитический: SI = CC50/IC50, и 0, если любого измерения нет.

Разбор top.csv: топ — выпуклая смесь точного ответа и ML-модели, веса дают ровно 1.0.

Model обрезана по нулю: на 126 строках model = 0, там top/exact = 0.9027598 ровно — топ хуже точного ответа.

$$\min_{\beta} \sum_{i=1}^{n} \left(y_i - x_i^{\top}\beta\right)^2 + \lambda \, \|\beta\|_1$$

РАЗБОР TOP-САБМИТА

$$SS_{between} = \sum_{k=1}^{K} n_k \, (\bar{x}_k - \bar{x})^2$$

$$MS_{between} = \frac{SS_{between}}{K-1}$$

$$SS_{within} = \sum_{k=1}^{K} \sum_{i:\, g_i=k} (x_i - \bar{x}_k)^2$$

$$MS_{within} = \frac{SS_{within}}{N-K}$$

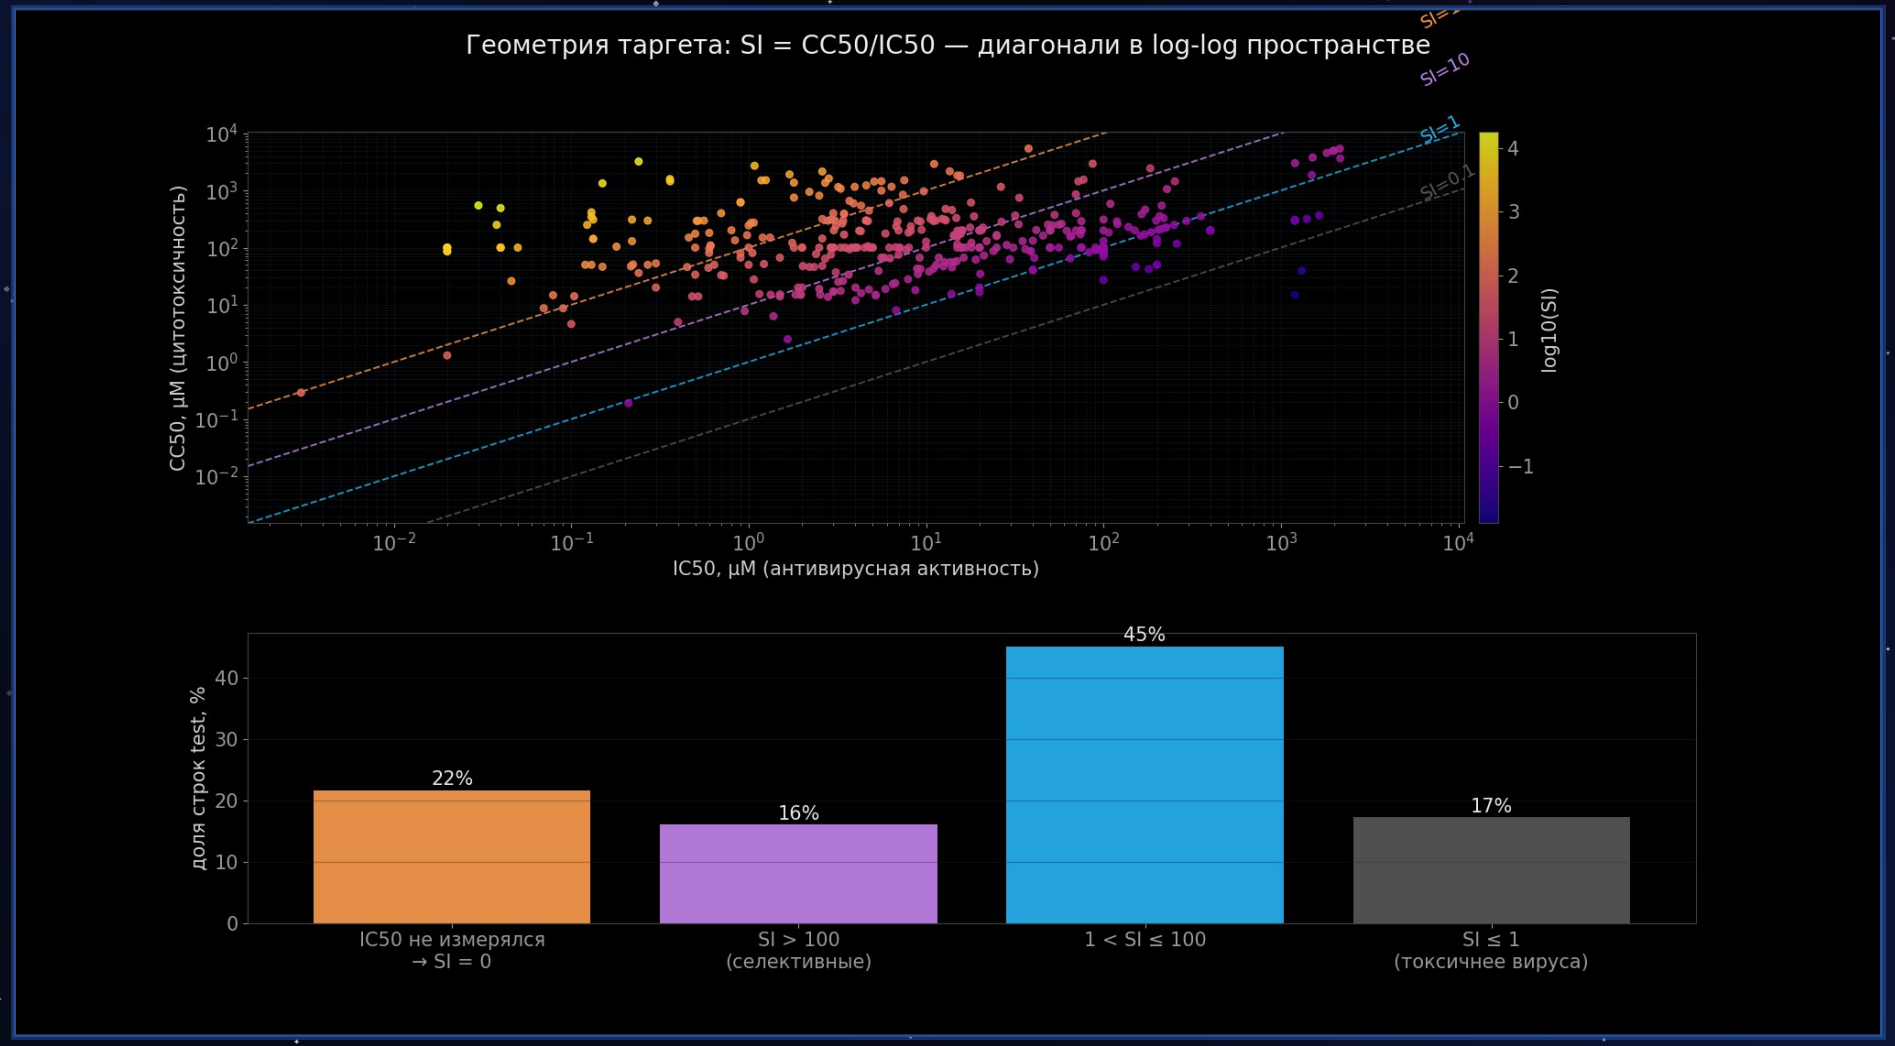
$$F = \frac{MS_{between}}{MS_{within}}$$

РЕЗУЛЬТАТЫ — ТОЧНЫЙ САБМИТ



EXACT SI = CC50/IC50 ПО СТРОКАМ TEST · SYMLOG · 129 СТРОК SI = 0

РЕЗУЛЬТАТЫ — ПРОВЕРКИ



CC50 VS IC50 (LOG-LOG) · ДИАГОНАЛИ — ЛИНИИ SI = CONST